

Yin-Yang

Detecția automată trăsăturilor de
personalitate pe baza analizei de
text scris de mână

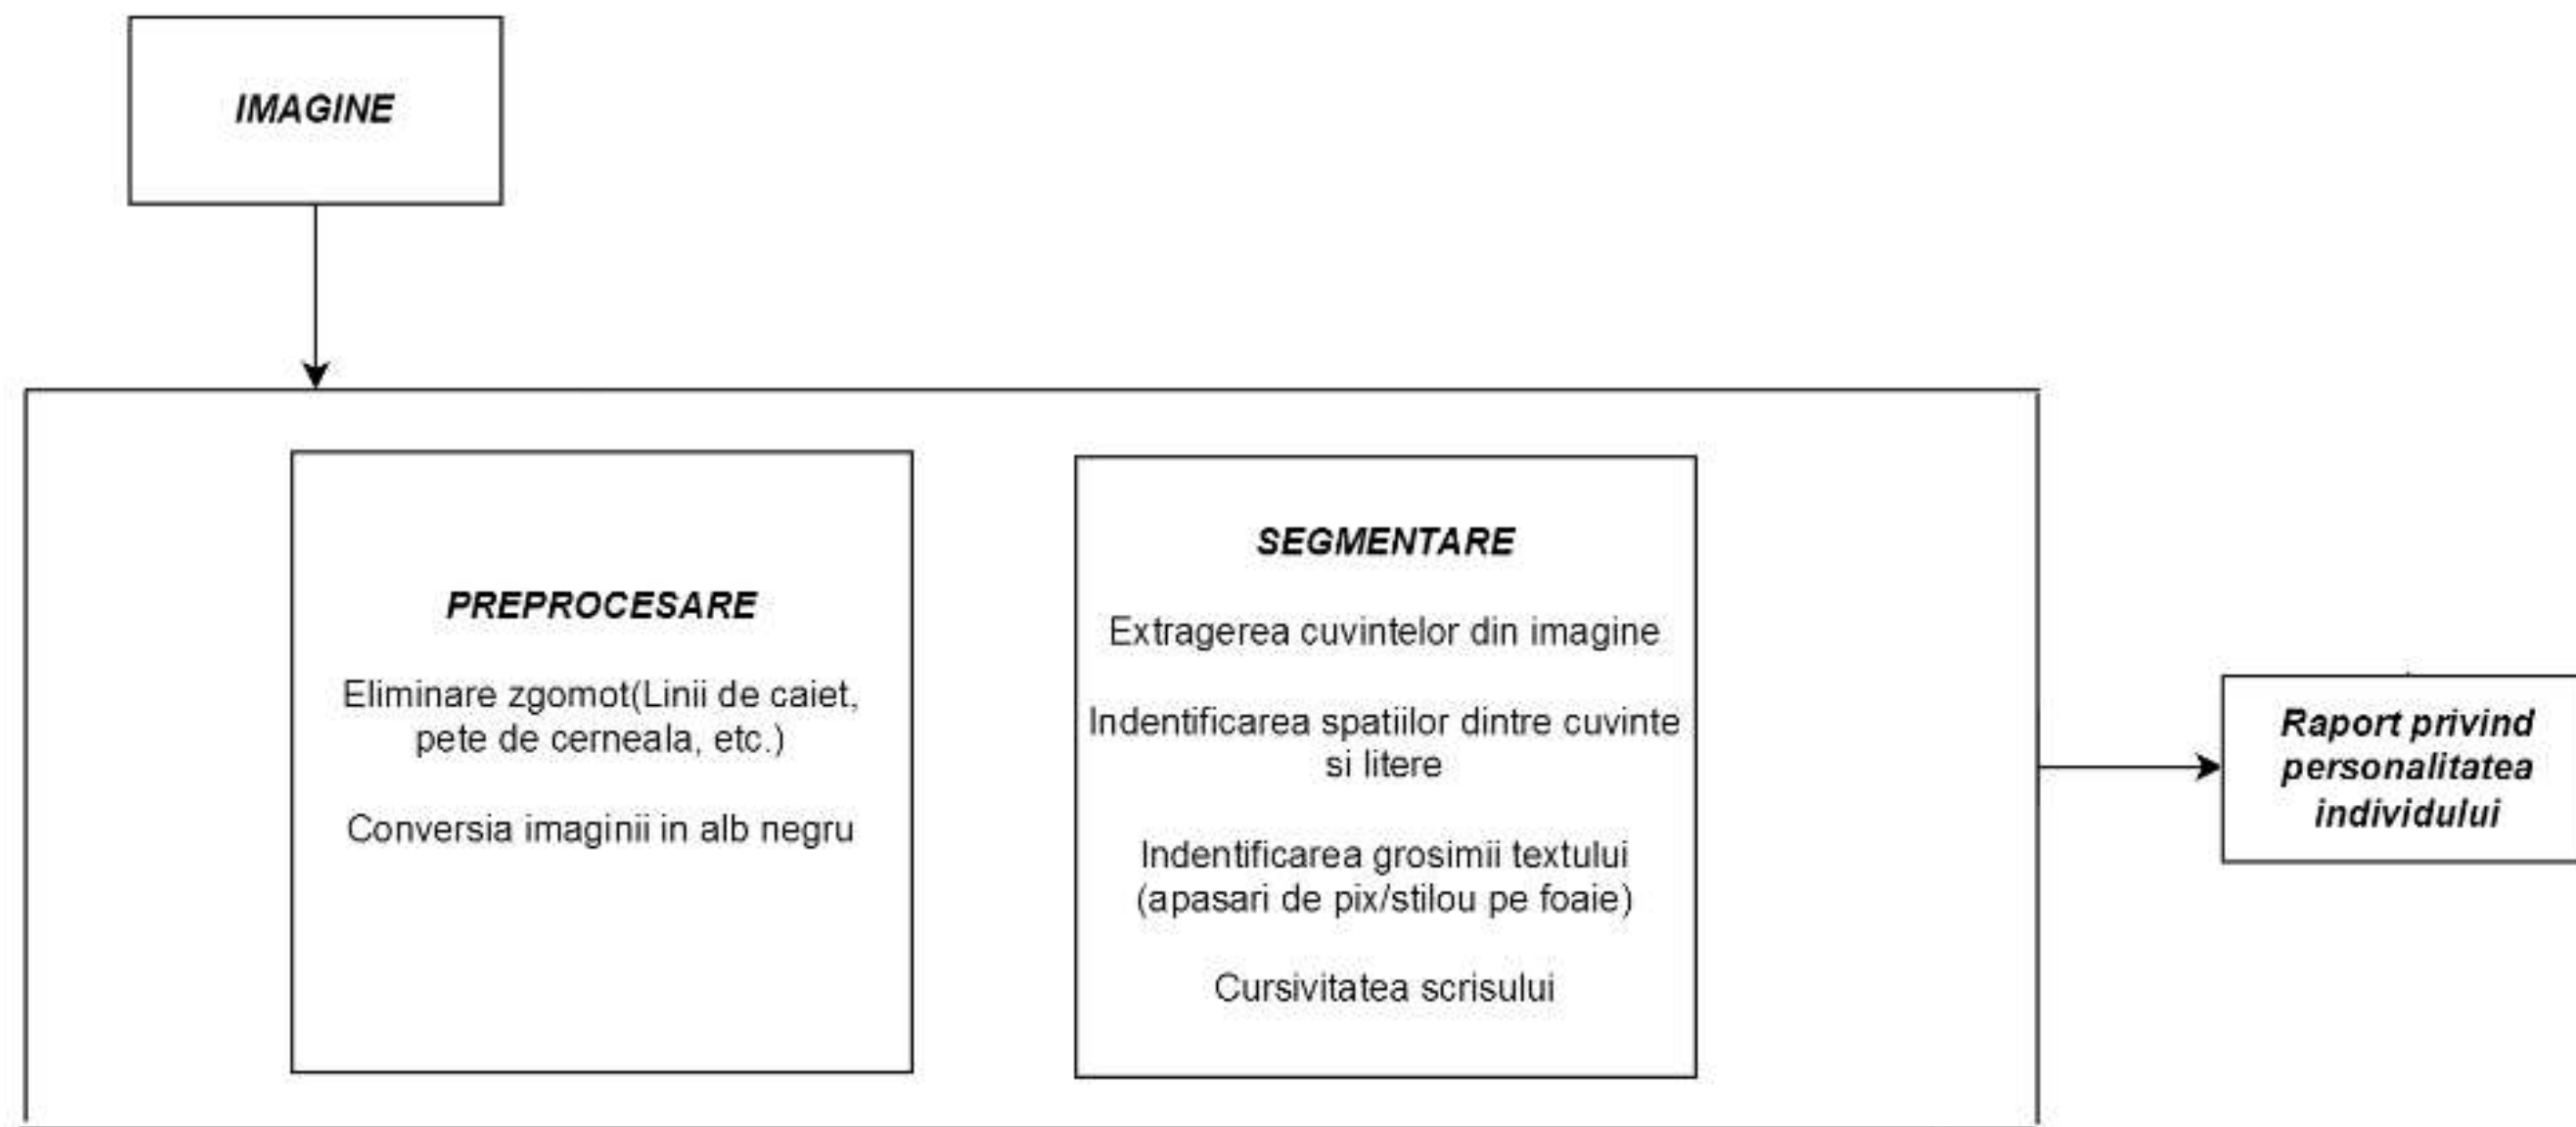
Popa Alexandru Serban
Chihalau Gabriel Eduard

1. Context & Motivație

- **Context:** Proiectul se ocupa cu analiza automata a scrisului de mana pentru a identifica trasaturi de personalitate. In prelucrarea imaginilor, asta inseamna recunoasterea si interpretarea elementelor vizuale din scris, cum ar fi forma literelor, spatierea si presiunea aplicata pe hartie.
- **Motivație:** Descifrarea personalitatii prin scris poate fi folosita in domenii ca recrutarea, psihologia sau consilierea. O astfel de solutie automata ar face procesul mai rapid si ar elimina erorile sau interpretarile subiective din analiza manuala.
- **Obiectivul proiectului:** Scopul proiectului este sa dezvolte o aplicatie Python care analizeaza scrisul de mana si detecteaza automat trasaturi de personalitate, oferind un raport rapid si obiectiv.

2. Arhitectura preliminară a soluției

- Schema arhitecturii:



2. Arhitectura preliminară a soluției

- **Descrierea componentelor:**

- Preprocesare: Curata imaginea si o pregateste pentru analiza.
- Segmentare: Separa literele si cuvintele din imagine.
- Extractie Trasaturi: Identifica elemente vizuale (grosime, spatiere, cursivitate)

pentru analiza.

- Clasificare: Foloseste o retea neuronală pentru a detecta trasaturi de personalitate.
- Generare Raport: Creeaza un raport bazat pe rezultatele clasificarii.

- **Fluxul de date:** Imaginea intra in modulul de Preprocesare, apoi trece prin Segmentare si Extractie Trasaturi. Datele obtinute sunt trimise catre Clasificare, iar rezultatele finale sunt folosite pentru a genera raportul.

3. Evaluarea Preliminară a Soluției

- **Metodologia de evaluare:** Am antrenat modelul folosind un set de date separat, evaluand performanta prin metrice standard (precizie, recall, scor f1). De asemenea, am utilizat matricea de confuzie pentru a analiza distributia predictiilor intre clase.
- **Setul de date:** Pentru antrenare, am folosit un set de date etichetat de pe platforma Kaggle, construit pe baza caracteristicilor extrase din imagini de scris de mana, cu trasaturi dominante definite. Evaluarea finala a fost realizata pe IAM Handwriting Dataset, ales pentru varietatea si complexitatea sa, fiind un standard in recunoasterea scrisului de mana.
- **Exemple de cazuri de test:** Un exemplu relevant este clasificarea unei imagini din IAM Dataset, unde modelul prezice scoruri pentru trasaturile Agreeableness, Conscientiousness, Extraversion, Neuroticism si Openness.

4. Rezultate Preliminare

- **Rezultate obținute:** Evaluarea preliminară a aratat o acuratețe medie de aproximativ 37% pe setul de testare, cu valori variate pentru metricile de performanță (precizie, recall) între clase. Deși aceste valori oferă o granularitate ridicată, ele nu sunt foarte intuitive pentru interpretare directă, sugerând nevoia de normalizare sau discretizare în intervale finite pentru o prezentare mai clară. Timpul mediu de procesare per imagine din IAM Dataset a fost de aproximativ o secundă, incluzând preprocesarea și predicția.


4. Rezultate Preliminare

- **Vizualizări:** Matricea de confuzie a ilustrat distributia predictiilor intre clase, evidentiind o performanta mai buna pentru trasaturi precum Neuroticism si Conscientiousness.
- Am folosit de asemenea ClassificationReport din biblioteca SKLearn pentru a vedea rezultatele detaliate ale antrenarii modelului.

```
PRECIZIE MODEL: 0.42105263157894735
Report clasificare din sklearn:
      precision    recall  f1-score   support

 Agreeableness      0.50      0.25      0.33         8
 Conscientiousness  0.29      0.57      0.38         7
  Extraversion      0.67      0.75      0.71         8
   Neuroticism      0.50      0.38      0.43         8
     Openness      0.20      0.14      0.17         7

 accuracy          0.43          0.42          0.42        38
 macro avg          0.43          0.42          0.40        38
 weighted avg          0.44          0.42          0.41        38
```



4. Rezultate Preliminare

- **Interpretarea rezultatelor:** Rezultatele obtinute indica faptul ca predictiile sub forma de valori numerice flotante sunt mai potrivite pentru evaluari comparative decat pentru utilizare directa in aplicatii. Performanta scazuta pentru trasaturi precum Agreeableness si Openness subliniaza necesitatea unor ajustari in preprocesare si echilibrare a datelor. Totusi, abordarea propusa demonstreaza potential in captarea tiparelor initiale din scris, iar o discretizare sau rotunjire a rezultatelor ar putea imbunatati semnificativ interpretabilitatea lor.

5. Concluzii Preliminare

- **Rezumatul progresului:** Am implementat un model ANN pentru clasificarea trasaturilor de personalitate pe baza scrisului de mana. Modelul a obtinut o acuratete de 42.1% si poate analiza imagini din setul IAM, generand scoruri pentru fiecare trasatura.
- **Limitările soluției actuale:**
 - Dezechilibru in date, afectand clasele mai putin reprezentate.
 - Performanta scazuta pentru trasaturi precum Openness si Agreeableness.
 - Scoruri flotante greu de interpretat.
 - Consumul ridicat de resurse pentru antrenare.

5. Concluzii Preliminare

- **Potențiale îmbunătățiri:**
 - Extinderea setului de date pentru clasele deficitare.
 - Augmentarea datelor pentru diversitate.
 - Testarea altor arhitecturi de rețea, precum CNN.
 - Scalarea scorurilor pentru interpretare mai ușoară.
 - Utilizarea transferului de învățare pentru eficiență sporită.

6. Direcții Viitoare

- **Pași următori:**

- Testarea extensivă a modelului pe setul IAM pentru validarea rezultatelor.
- Adăugarea unor metode de augmentare a datelor pentru echilibrarea claselor.
- Optimizarea rețelei prin ajustarea hiperparametrilor și testarea cu alte rate de învățare.
- Implementarea unui mecanism de scalare a scorurilor pentru interpretare mai clară.
- Compararea rezultatelor cu alte proiecte similare pentru validare externă.

6. Direcții Viitoare

- **Plan de implementare:**

- Vom extinde sau inlocui setul de date pentru ca modelul sa obtina o precizie mai mare in urma antrenarii
- Vom ajusta dropout-ul si numarul de neuroni pentru a reduce overfitting-ul
- Vom testa noul model pe mai multe seturi de date publice

- **Obiectivele finale:**

- Dorim sa obtinem o precizie de cel putin 75% pe cel putin trei trasaturi
- Dorim sa generam rezultate mai usor de interpretat pentru utilizatori
- Dorim sa cream o interfata usor de inteles pentru utilizator in care vom afisa toate informatiile relevante procesului de parcurgere, analizare si clasificare